2026-11-09 · ЛИЧНЫЙ ОПЫТ, А НЕ ОБЗОР РЫНКА

Локальный AI на одном ноутбуке

Что я построил, что сломал и чему научился

Дмитрий Потехин · 33 минуты плана + 2 минуты резерва · 20 слайдов · 2026-11-09

АКТ 1 — РЕЗУЛЬТАТ · АКТ 2 — ПОД КАПОТОМ · АКТ 3 — ПРОВАЛЫ И ВЫВОДЫ

EXECUTED
2026-11-09

HISTORICAL
раньше

RECORDING
запись

OFFLINE VALIDATION
граф

PLANNED
не проверено

Источники: 00-audit/ · research/ · demo/ · 01-history/ · коммиты ecef65e, a5d76a3, 1c3279f

HISTORICAL

Железо: одна память на двоих

96,0 GiB
доступно GPU

29,7 GiB
host RAM

125,7 GiB
суммарно unified LPDDR5X

ROG Flow Z13 GZ302EA · Ryzen AI MAX+ 395 · 32 потока · Ubuntu 26.04.1 LTS, ядро 7.0.0-42-generic
VRAM 103 079 215 104 B · MemTotal 31 961 256 kB

ПОЧЕМУ ЭТО НЕ 128 ГБ VRAM

- 128 ГБ — характеристика платформы AMD 2025, а не запас в системе
- видно 96,0 GiB под GPU и 29,7 GiB host: это одна LPDDR5X, поделённая драйвером

ОДНА БОЛЬШАЯ МОДЕЛЬ — ЦЕЛИКОМ

- 19,72 GiB MoE грузится целиком, модель не режется на части
- но llama.cpp (Vulkan, хост) и ComfyUI (ROCm, контейнер) не занимают её одновременно

Диск 937 G, свободно 606 G. 128 ГБ, 50+ TOPS NPU и RDNA 3.5 — внешние характеристики платформы, а не замеры этой машины.

HISTORICAL

Что реально лежит на диске

LLM — ТРИ МОДЕЛИ НА ДИСКЕ

- Qwen3.8-27B Q4_K_M — 16,24 GiB, dense
- Qwen3.5-35B-A3B Q4_K_M — 19,72 GiB, MoE, community fine-tune
- Qwen2.5-Coder-32B Q4_K_M — 18,49 GiB

МЕДИА — ЧЕКПОЙНТЫ И ВИДЕО

- SDXL Turbo fp16 — 6,46 GiB, 4 шага
- Animagine XL 4.0 — 6,46 GiB, 28 шагов
- MiniMax H3 — 2 × 19,52 GiB + 5 видео-LoRA
- Wan 2.2 TI2V 5B — 9,31 GiB fp16

Всё лежит локально: 13 папок моделей, свободно 606 G диска. Инвентарь снят с диска и из базы студии — под доклад ничего не докачивалось.

EXECUTED

Живое демо 9 ноября

7,52 с
txt2img-turbo · 1024² · 4 шага

2,16 с
sam-cutout · MobileSAM · точка 560,520

4,51 с
sam-object-remove · FAILED

- три прогона подряд, 20:24–20:25 MSK, реальный JobManager и реальный ComfyUI
- живого GPU-времени — 9,7 с (в плане было 13,4 с)
- VRAM возвращается к 95,3 GiB: модели не удерживаются между заданиями
- третий прогон упал — разбор на слайде 19



turbo_00011_.png · 1 975 686 B · 7,52 с

> Единственный блок, прогнанный вживую 9 ноября: время, job id и файлы — на диске.

demo/stage3-timings.md

HISTORICAL

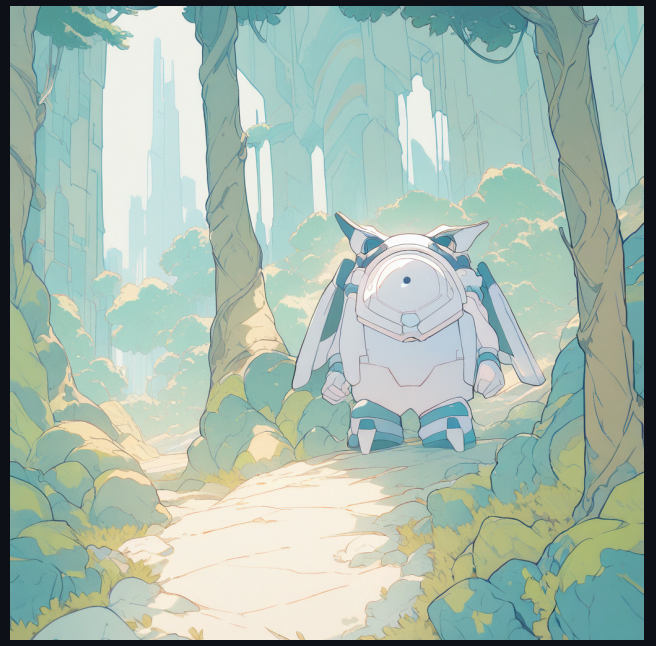
Аниме: три файла, три режима



animagine · 28 шагов · 26,47 с



style_anime · 32,53 с



restyle · img2img denoise 0,55 · 27,62 с

img2img с denoise 0,55 сохраняет композицию кадра и перерисовывает стиль. Все три файла — из output/studio, прогоны 26 октября.

EXECUTED

Сегментация по одной точке

- MobileSAM, одна точка — 560,520: без бокса, без текстового промпта
- 2,16 с на CPU: модель ONNX, GPU в это время свободна
- sha256 7849efdc34c9… — побайтово совпал с прогоном 26 октября
- значит host-сегментация воспроизводима: тот же вход даёт тот же файл



> Детерминизм доказан сравнением файлов, а не повторным «на глаз».

sam_cutout_00023_.png · 1 869 291 B

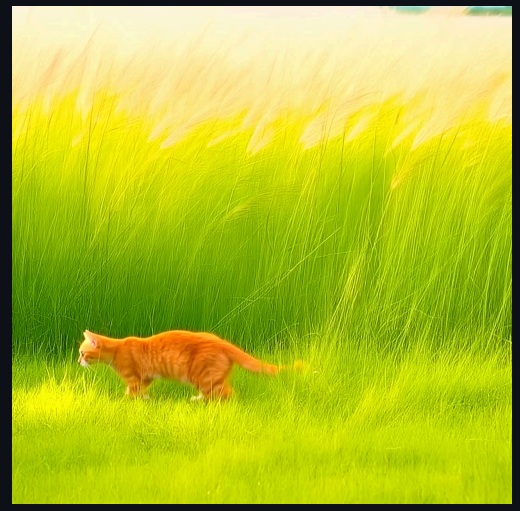
demo/stage3-timings.md (прогон 2)

RECORDING

Видео: только записью



h3_fast_768x448.mp4 · 5,18 с



постер Wan 2.2 · клип 2,04 с

ПОЧЕМУ ЗАПИСЬЮ

- живой QUALITY — 3 ч 14 мин счёта
- WAN 1280² — 51,6 с на шаг
- в зале это недопустимо: показываем файл

337,84 с

генерация FAST-клипа 5,18 с

1 610,57 с

WAN 2.2 при 1280², клип 2,04 с

11 652 с

QUALITY: 12,28 с, ×34,5

Все четыре ролика — записи: на 12 секунд видео ушло 3 ч 14 мин счёта. Вживую видео не запускается.

HISTORICAL

Hugging Face и Civitai: как выбирать

HUGGING FACE

- фильтры: задача · размер · лицензия
- GGUF — для llama.cpp, safetensors — для ComfyUI
- Q4_K_M: 27B = 16,24 GiB вместо ~54 GiB fp16

CIVITAI

- карточка модели: базовая архитектура, примеры, лицензия
- чекпойнт — вся модель, LoRA — адаптер поверх неё
- SDXL-адаптер не встанет на SD 1.5 и наоборот

- ничего не скачивалось под доклад: инвентарь снят с диска и из базы студии
- что лежит на диске — определяет, что можно показать завтра, а что только записью

> Формат файла важнее названия: одна модель в GGUF и в safetensors — два разных адресата, и путать их нельзя.

PLANNED

LoRA: что могу показать, а что нет

100–200 МБ
адаптер вместо полной модели

0
image-LoRA под SDXL на диске

5
видео-LoRA MiniMax H3

- LoRA меняет стиль без переобучения: веса базовой модели не трогаются
- на диске 1,82 / 1,82 / 1,82 / 11,6 / 1,15 GiB — это видео-LoRA H3, к SDXL они не относятся
- показывать «до/после» нечего: файла нет, демонстрация невозможна

> Чтобы показать LoRA честно, нужно: (1) скачать SDXL-LoRA и разрешить загрузку; (2) проверить совместимость базовой модели; (3) прогнать до/после и сохранить оба файла.

HISTORICAL

Два стека и их цифры

ХОСТ: LLAMA.CPP, VULKAN

- build 11721, коммит ff5a23376 — 18 октября
- 35B-A3B: 70,4 tok/s генерация, prefill 1246 tok/s
- контекст 131072; на 128K — 36,0 tok/s, падение 1,96×
- модель 19,72 GiB лежит целиком в памяти

КОНТЕЙНЕР: COMFYUI, ROCM 7.2.0

- 0.44.0, torch 2.9.1+rocm7.2.0
- 1360 классов узлов, 13 папок моделей
- 127 определений в реестре, свободно 95,3 GiB
- 1280^2: 51,6 с на шаг (WAN 2.2)

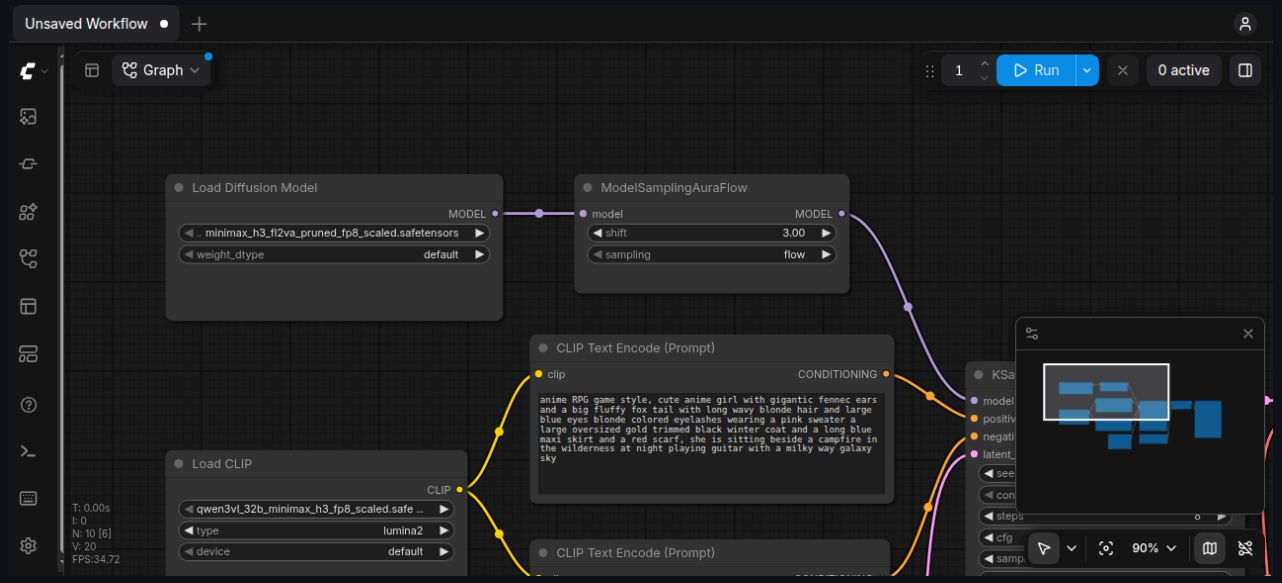
- цифры разных стеков нельзя складывать: разные бэкенды и форматы весов
- /opt/rocm на хосте отсутствует — LLM и медиа живут на разных рантаймах

> Падение с 70,4 до 36,0 tok/s на 128K — не «медленная модель», а цена контекста.

research/inference-explained.md · research/hardware-analysis.md

HISTORICAL

Как читать workflow



реальный экран студии · граф MiniMax H3

- поток слева направо: модель → условие → сэмплер → декодер → файл
- узел — маленькая программа со своими входами и выходами
- промпт — такой же вход, как модель и разрешение
- читать граф дешевле, чем запускать его

скриншот студии · 2026-11-09 · workflow H3

HISTORICAL

Три ручки, которые всё решают

4 ↔ 28
шагов: Turbo против аниме

1,0 ↔ 6,0
cfg: Turbo против аниме

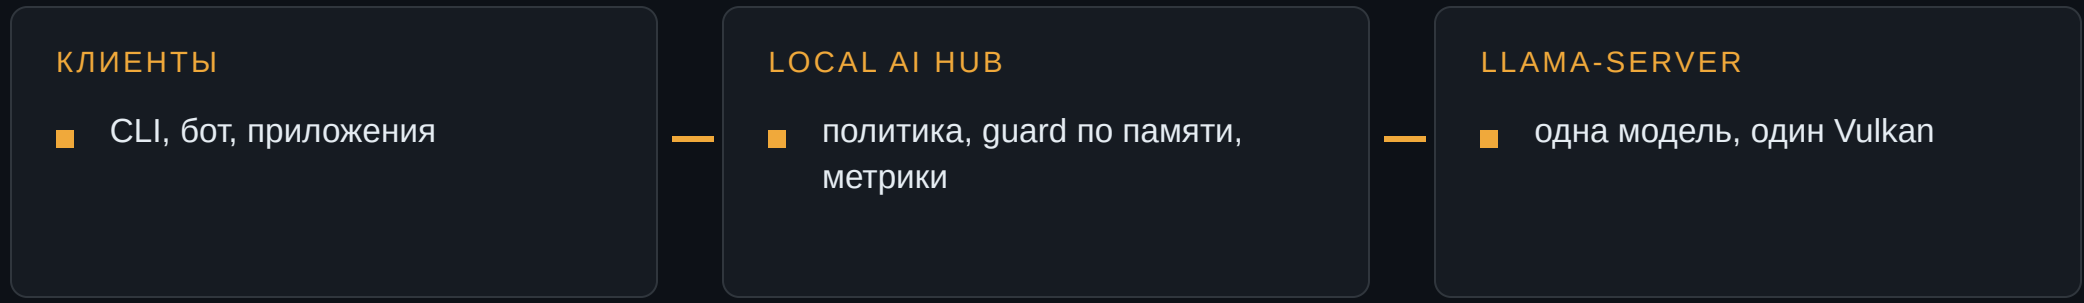
seed
воспроизводимость результата

- 7,52 с — Turbo, 1024², 4 шага, cfg 1,0, seed 4242 (EXECUTED 9 ноября)
- 26,47 с — аниме, 28 шагов, cfg 6,0 (HISTORICAL 26 октября)
- это разные режимы, а не «медленная модель»: сравнивать надо при равных ручках

> Seed 4242 в Turbo и 3273027029116907681 в аниме — поэтому файлы воспроизводятся, а не «примерно похожи».

HISTORICAL

Local AI Hub: политика вместо прокси



- OpenAI-совместимый API: клиент не знает, что модель локальная
- guard отказывает, если запрос просит больше 12 GiB VRAM
- метрики и трейсы: видно, кто, что и сколько сжёг

> Хаб — это политика, а не прокси: лимиты и учёт появились раньше второго клиента.

HISTORICAL

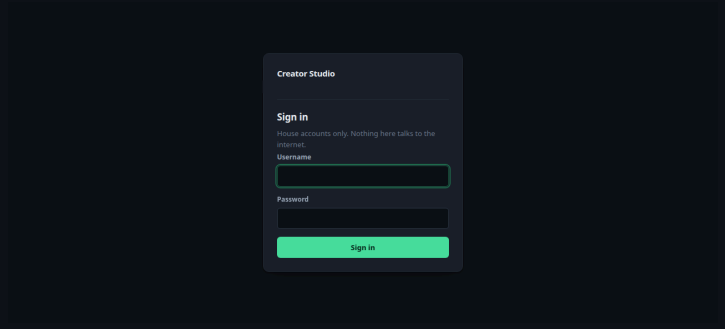
Два приложения поверх движка

COMFYUI STUDIO — ДВИЖОК КАК СЕРВИС

- очередь и история: 154 job — 141 completed, 10 failed, 3 cancelled
- RBAC, argon2id, CSRF-токен на изменяющих запросах
- 1764 теста backend, 149 с, exit 0 (2026-11-08)

CAROUSEL GENERATOR — ПРОДУКТ ПОВЕРХ

- 3 слайда, цикл 180 с в живом прогоне
- 293 теста passed: 29 файлов, 5 601 строка
- LLM пишет контент, а не код



вход в студию · адрес скрыт

> Движок ≠ сервис: ComfyUI умеет считать, но не умеет очередь, права и историю.

00-audit/project-inventory.md · reports/RELEASE_CANDIDATE…

OFFLINE VALIDATION

Офлайн-валидация графов

- в реестре ~127 определений, и они разные по природе: graph — это prompt, host — подпроцесс, chain — препроцессор графа
- режим решает, что проверять: у host нет графа, и спрашивать node registry про ffmpeg_trim бессмысленно
- graph: класс узла в живом /object_info, обязательные входы, типы литералов, связи, файлы весов
- 12 workflow проверены офлайн; узлы не исполняются — «валидно» не значит «сработает»

> Warn-first: сам валидатор ничего не блокирует — блокировка это отдельное политическое решение. Коммит 1c3279f.

PLANNED

PLAN_ONLY: план, а не запуск

1. ПРОМПТ

- человек формулирует задачу

2. ПЛАН

- LLM предлагает шаги

3. ГРАФ

- валидатор проверяет структуру

4. ЗАПУСК

- отдельное разрешение

- генерация графа и запуск — разные разрешения: план не запускает GPU
- без подтверждения план не создаёт job (approval_required)
- на GPU ничего не запускалось: это спецификация, а не прогон

> Смысл ровно в этом: дорогую операцию проверяют дешёвой.

HISTORICAL

Провал 1: маска наоборот

1 из 2
workflow был сломан

178
тестов проходит после фикса

2,16 с
тот же путь cutout после починки

- симптом: вырезался объект вместо фона — и только на одном из двух workflow
- причина: инверсия маски перед композитом, а не ошибка модели
- урок: полярность маски — контракт между шагами, его надо фиксировать тестом

> Дефект нашёл глаз на рендере, а не тест. После фикса полярность закреплена тестом, а не памятью автора.

ecef65e · studio/backend/tests/test_registry_real.py

HISTORICAL

Провал 2: 640 превратилось в 1280

640²	1280²	51,6 с
столько запрошено в графе	столько на выходе	на шаг, 30 шагов

- клип 2,04 с стоит 1 610,57 с счёта — 26 мин 50 с
- время растёт нелинейно: вместе с площадью кадра, а не с длительностью
- форма врёт: половина разрешения в графе — полный кадр на выходе

> Разрешение — это бюджет, а не настройка: считать до запуска. Коммит a5d76a3.

EXECUTED

Провал 3: инпейнт не стартовал

```
File "/opt/ComfyUI/nodes.py", line 446, in encode
    mask_erosion = torch.clamp(torch.nn.functional.conv2d(mask.round(),
        kernel_tensor, padding=padding), 0, 1)
RuntimeError: Expected all tensors to be on the same device, but got weight
is on cpu, different from other tensors on cuda:0
```

- kernel_tensor создан без .to(device) — на CPU, а маска приходит с cuda:0
- условие падения: grow_mask_by != 0 плюс маска на GPU; задеты 6 инпейнт-workflow
- не чинил: это чужой релиз ComfyUI 0.44.0, обход — запись прогона 26 октября

> Разница между «мой код» и «чужой релиз» — в том, кому принадлежит фикс.

ИТОГ

Что осталось за границей

ГРАНИЦЫ — ЧЕСТНО

- весов SAM 3 нет: text-to-mask не показываем
- image-LoRA под SDXL нет ни одного файла
- 6 инпейнт-workflow заблокированы дефектом ComfyUI 0.44.0
- сквозной S1 end-to-end = BLOCKED
- утилизация GPU = LOW confidence: источники расходятся
- PLAN_ONLY — спецификация, не исполнение

ТРИ ВЫВОДА

- **Модель — это ещё не инфраструктура**
  веса не дают ни очереди, ни прав, ни истории
- **Проверять дешевле, чем исполнять**
  валидатор графа стоит секунды, прогон — минуты
- **Локальный контур — про контроль**
  повторяемость важнее рекордов скорости

Одно действие для зала: начните с SDXL Turbo — 4 шага, cfg 1,0 — результат в тот же вечер.